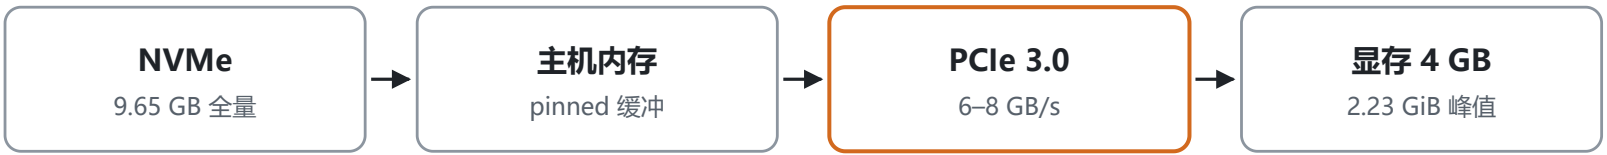
同一个 token 的两条数据通路

① 独立显卡架构（本文实测）



每 token 都要搬 1.35 GB 过 PCIe → 上限约 5 tok/s（实测 2.64–3.01）

② 统一内存架构（手机 SoC）

统一内存（LPDDR5X，50–70 GB/s）

CPU · GPU · NPU 共用同一块物理内存：不需要 pinned 缓冲、不需要 H2D、不需要双缓冲槽位

UFS 4.0

冷门专家按需读

热专家常驻 LPDDR5X → 理论上限 30–35 tok/s；全冷走 UFS → 1.5–3 tok/s