llama.cpp 与 ECS 为同机同模型实测（RTX 3050 Laptop 4 GB + Ryzen 5 5600H）；手机两行为按 1.35 GB/token 推算的区间