# MoE 消融：同一份 Q4_K_M，单请求贪心解码

单位 tok/s；条形表示实测区间

数据来源：docs/ARTICLE_9_DEEPSEEK_V2_LITE_MOE_CPU_GPU_OFFLOAD.md