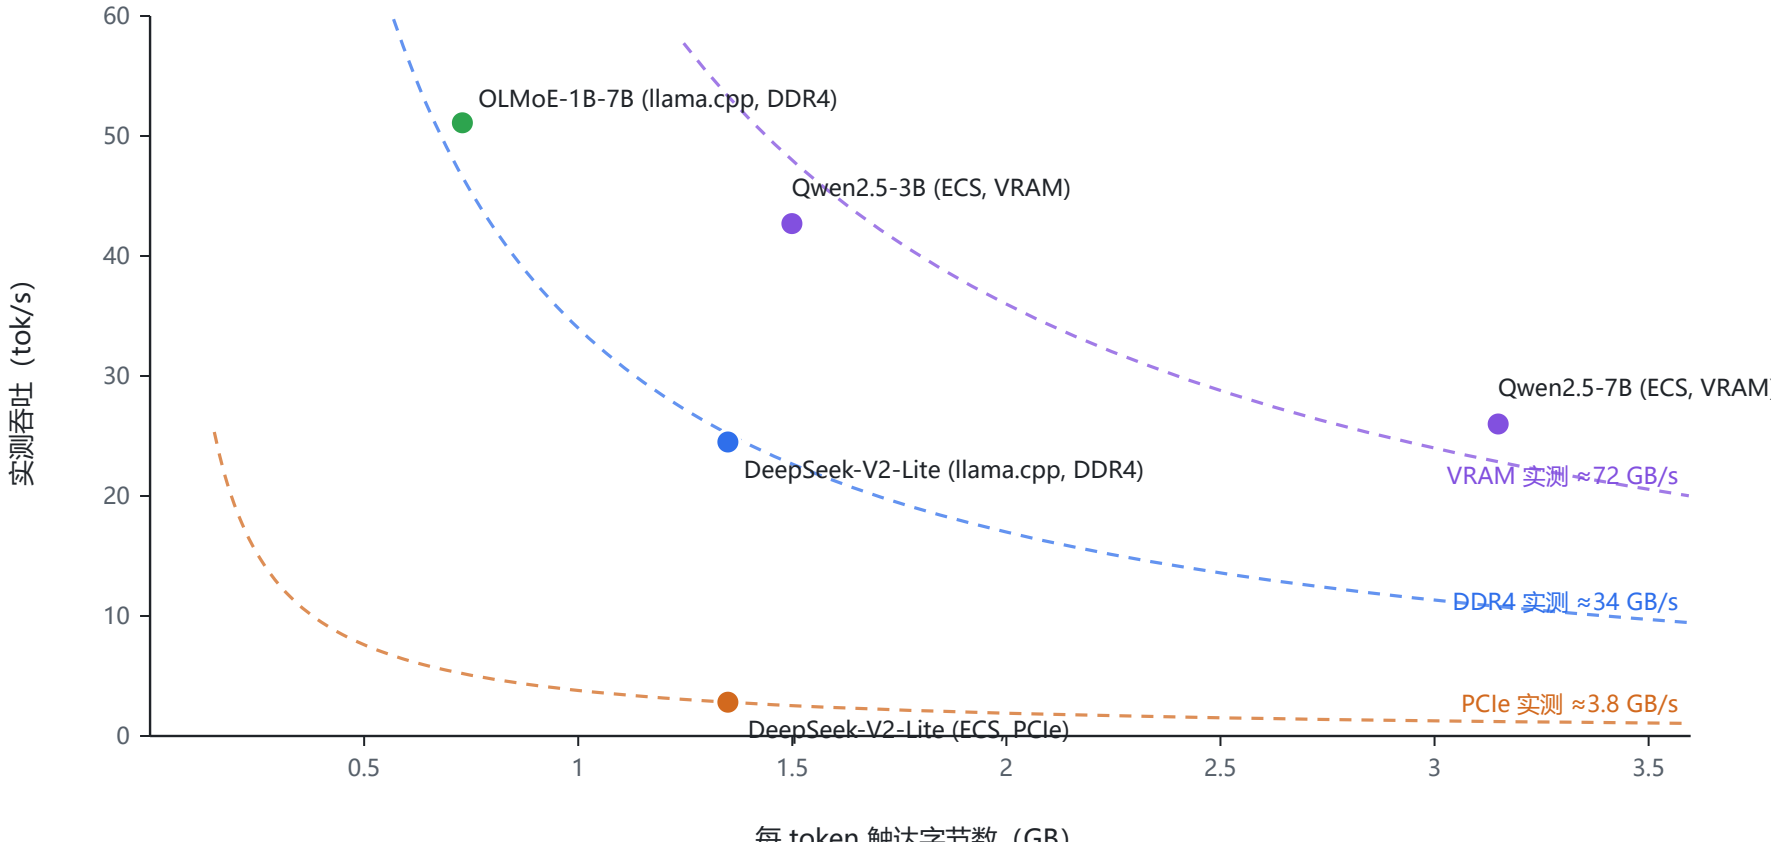
吞吐 vs 每 token 触达字节数

同一条虚线 = 同一个有效带宽；点越靠近哪条线，说明瓶颈就是那条通路



同一个 DeepSeek-V2-Lite 在 llama.cpp（DDR4）与 ECS（PCIe）上相差 8.7×，因为两点分属不同的带宽曲线；两个不同架构的 MoE 落在同一条 DDR4 曲线上。